XAI FINAL

Tufan BOSTAN

25127215588

```
#libraries
library(dplyr)
library(xgboost)
library(DALEX)
library(lightgbm)
library(party)
library(e1071)
library(gbm)
```

forestfires

```
forestfires <- read.csv(paste0(getwd(),"/forestfires.csv"))
head(forestfires)</pre>
```

```
##
    X Y month day FFMC DMC
                              DC ISI temp RH wind rain area
## 1 7 5
          mar fri 86.2 26.2 94.3 5.1 8.2 51 6.7
## 2 7 4
          oct tue 90.6 35.4 669.1 6.7 18.0 33
                                              0.9
                                                   0.0
                                                         0
## 3 7 4
          oct sat 90.6 43.7 686.9 6.7 14.6 33
                                                   0.0
                                              1.3
                                                         0
## 4 8 6
          mar fri 91.7 33.3 77.5 9.0 8.3 97
                                              4.0
                                                   0.2
                                                         0
## 5 8 6
          mar sun 89.3 51.3 102.2 9.6 11.4 99
                                              1.8 0.0
                                                         0
## 6 8 6
          aug sun 92.3 85.3 488.0 14.7 22.2 29 5.4 0.0
                                                         0
```

summary(forestfires)

```
##
         Χ
                         Y
                                   month
                                                       day
                   Min. :2.0
   Min. :1.000
                                Length:517
                                                   Length:517
##
   1st Qu.:3.000
                   1st Qu.:4.0
                                Class :character
                                                   Class : character
  Median :4.000
                   Median:4.0
                                Mode :character
                                                   Mode :character
##
  Mean
         :4.669
                   Mean
                        :4.3
##
   3rd Qu.:7.000
                   3rd Qu.:5.0
          :9.000
                         :9.0
##
  Max.
                   Max.
##
        FFMC
                       DMC
                                        DC
                                                       ISI
                                                  Min. : 0.000
## Min. :18.70
                   Min. : 1.1
                                  Min. : 7.9
##
   1st Qu.:90.20
                   1st Qu.: 68.6
                                  1st Qu.:437.7
                                                  1st Qu.: 6.500
## Median :91.60
                   Median :108.3
                                  Median :664.2
                                                  Median: 8.400
## Mean :90.64
                   Mean :110.9
                                  Mean :547.9
                                                  Mean : 9.022
                   3rd Qu.:142.4
                                  3rd Qu.:713.9
## 3rd Qu.:92.90
                                                  3rd Qu.:10.800
```

```
##
            :96.20
                              :291.3
                                               :860.6
                                                                 :56.100
    Max.
                      Max.
                                       Max.
                                                         Max.
                            RH
##
                                                                rain
          temp
                                              wind
    Min.
            : 2.20
##
                      Min.
                              : 15.00
                                        Min.
                                                :0.400
                                                          Min.
                                                                  :0.00000
    1st Qu.:15.50
                      1st Qu.: 33.00
                                        1st Qu.:2.700
                                                          1st Qu.:0.00000
##
##
    Median :19.30
                      Median: 42.00
                                        Median :4.000
                                                          Median :0.00000
            :18.89
                              : 44.29
                                                :4.018
                                                                  :0.02166
##
    Mean
                      Mean
                                        Mean
                                                          Mean
                      3rd Qu.: 53.00
##
    3rd Qu.:22.80
                                        3rd Qu.:4.900
                                                          3rd Qu.:0.00000
##
    Max.
            :33.30
                      Max.
                              :100.00
                                        Max.
                                                :9.400
                                                          Max.
                                                                  :6.40000
##
          area
##
    Min.
            :
                0.00
##
    1st Qu.:
                0.00
##
    Median:
                0.52
##
    Mean
               12.85
##
    3rd Qu.:
                6.57
            :1090.84
##
    Max.
```

Bu veri kümesi, Portekiz'in kuzeydoğu bölgesindeki orman yangınlarının etkilediği alanın tahmin edilmesi amacıyla oluşturulmuştur. Veri seti, yangınların koordinatları, yangın tarihi ve çeşitli meteorolojik koşullar gibi bir dizi faktörü içermektedir. Bu faktörler, orman yangınlarının şiddetini ve yayılmasını etkileyen önemli bileşenlerdir. Veri seti, öncelikle "area" adlı çıktı değişkeni üzerine odaklanır. Bu değişken, orman yangınının neden olduğu alanın büyüklüğünü ifade eder.

- 1. X x-ekseni koordinatı (1 ile 9 arasında değerler alır).
- 2. Y y-ekseni koordinatı (2 ile 9 arasında değerler alır).
- 3. Month Yangın ayı (Ocak'tan Aralık'a kadar 12 farklı ayı temsil eden üç harfli kısaltmalarla, örneğin "jan" veya "aug").
- 4. Day Yangın günü (Pazartesiden Pazar'a kadar 7 farklı günü temsil eden 1 ile 7 arasında tam sayılar).
- 5. FFMC Fine Fuel Moisture Code, nem kodu (18.7 ile 96.20 arasında değerler alır).
- 6. DMC Duff Moisture Code, duff nem kodu (1.1 ile 291.3 arasında değerler alır).
- 7. DC Drought Code, kuruluk kodu (7.9 ile 860.6 arasında değerler alır).
- 8. ISI Initial Spread Index, başlangıç yayılma indeksi (0.0 ile 56.10 arasında değerler alır).
- 9. Temp Sıcaklık (2.2 ile 33.30 arasında değerler alır).
- 10. RH Relatif Nem (15 ile 100 arasında değerler alır).
- 11. Wind Rüzgar hızı (0.40 ile 9.40 arasında değerler alır).
- 12. Rain Yağış (0.0 ile 6.4 arasında değerler alır).
- 13. Area Orman yangınının etkilediği alanın büyüklüğü (sıfır veya pozitif gerçek sayılar, çoğunlukla sıfıra vakın).


```
# Ay ve gün eşleme tablolarının oluşturulması
month_map <- c(
    'jan' = 1,
    'feb' = 2,
    'mar' = 3,
    'apr' = 4,
    'may' = 5,
    'jun' = 6,
    'jul' = 7,
    'aug' = 8,
    'sep' = 9,
    'oct' = 10,
    'nov' = 11,
    'dec' = 12
)</pre>
```

```
day_map <- c(</pre>
 'sun' = 7,
 'mon' = 1,
 'tue' = 2,
 'wed' = 3,
 'thu' = 4,
 'fri' = 5,
 'sat' = 6
)
# forestfires veri setindeki 'month' sütununu eşleme tablosuyla değiştirme
forestfires <- forestfires %>%
 mutate(month = month_map[month])
# forestfires veri setindeki 'day' sütununu eşleme tablosuyla değiştirme
forestfires <- forestfires %>%
 mutate(day = day_map[day])
# forestfires veri setinin yapısını inceleme
str(forestfires)
## 'data.frame':
                 517 obs. of 13 variables:
## $ X : int 7 7 7 8 8 8 8 8 8 7 ...
## $ Y : int 5 4 4 6 6 6 6 6 5 ...
## $ month: Named num 3 10 10 3 3 8 8 8 9 9 ...
   ..- attr(*, "names")= chr [1:517] "mar" "oct" "oct" "mar" ...
## $ day : Named num 5 2 6 5 7 7 1 1 2 6 ...
   ..- attr(*, "names")= chr [1:517] "fri" "tue" "sat" "fri" ...
## $ FFMC: num 86.2 90.6 90.6 91.7 89.3 92.3 92.3 91.5 91 92.5 ...
## $ DMC : num 26.2 35.4 43.7 33.3 51.3 ...
## $ DC : num 94.3 669.1 686.9 77.5 102.2 ...
## $ ISI : num 5.1 6.7 6.7 9 9.6 14.7 8.5 10.7 7 7.1 ...
## $ temp : num 8.2 18 14.6 8.3 11.4 22.2 24.1 8 13.1 22.8 ...
## $ RH : int 51 33 33 97 99 29 27 86 63 40 ...
## $ wind : num 6.7 0.9 1.3 4 1.8 5.4 3.1 2.2 5.4 4 ...
## $ rain : num 0 0 0 0.2 0 0 0 0 0 ...
## $ area : num 0000000000...
# Veri Setinin Bölünmesi
set.seed(123) # Tekrarlanabilirlik için
sample <-
 sample.int(
   n = nrow(forestfires),
   size = floor(.8 * nrow(forestfires)),
   replace = FALSE
 )
# Eğitim veri setini oluşturma
train_data <- forestfires[sample,]</pre>
train_data_ff <- train_data</pre>
glimpse(train_data, width = 44)
```


```
## Rows: 413
## Columns: 13
## $ X
           <int> 5, 1, 2, 2, 3, 8, 4, 7, 6, 5~
           <int> 4, 4, 5, 2, 4, 6, 6, 4, 5, 4~
## $ Y
## $ month <dbl> 8, 9, 9, 8, 3, 6, 9, 8, 9, 8~
           <dbl> 7, 7, 3, 2, 6, 3, 7, 7, 1, 4~
## $ day
## $ FFMC <dbl> 93.6, 91.0, 90.1, 94.8, 91.7~
           <dbl> 235.1, 276.3, 82.9, 108.3, 3~
## $ DMC
## $ DC
           <dbl> 723.1, 825.1, 735.7, 647.1, ~
## $ ISI
           <dbl> 10.1, 7.1, 6.2, 17.0, 7.8, 1~
## $ temp <dbl> 24.1, 14.5, 18.3, 24.6, 15.2~
           <int> 50, 76, 45, 22, 27, 43, 26, ~
## $ RH
## $ wind <dbl> 4.0, 7.6, 2.2, 4.5, 4.9, 4.9~
## $ rain <dbl> 0, 0, 0, 0, 0, 0, 0, 1, 0, 0~
## $ area <dbl> 0.00, 3.71, 4.88, 10.01, 0.0~
# Test veri setini oluşturma
test_data <- forestfires[-sample,]</pre>
glimpse(test_data, width = 44)
## Rows: 104
## Columns: 13
## $ X
           <int> 7, 8, 6, 5, 8, 6, 6, 7, 4, 5~
## $ Y
           <int> 5, 6, 5, 5, 5, 4, 3, 4, 4, 6~
## $ month <dbl> 3, 9, 9, 3, 10, 3, 10, 10, 9~
## $ day
           <dbl> 5, 2, 3, 6, 1, 3, 2, 5, 6, 3~
## $ FFMC <dbl> 86.2, 91.0, 92.9, 91.7, 84.9~
## $ DMC
           <dbl> 26.2, 129.5, 133.3, 35.8, 32~
## $ DC
           <dbl> 94.3, 692.6, 699.6, 80.8, 66~
## $ ISI
           <dbl> 5.1, 7.0, 9.2, 7.8, 3.0, 6.3~
## $ temp <dbl> 8.2, 13.1, 26.4, 15.1, 16.7,~
           <int> 51, 63, 21, 27, 47, 35, 24, ~
## $ RH
## $ wind <dbl> 6.7, 5.4, 4.5, 5.4, 4.9, 4.0~
## $ rain <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0~
## $ area <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0~
```

XGBoost

```
xgb_explainer <-</pre>
 DALEX::explain(xgb_model, data = as.matrix(train_data[, -13]), y = train_data$area)
## Preparation of a new explainer is initiated
    -> model label : xgb.Booster ( default )
##
##
    -> data
                        : 413 rows 12 cols
    -> target variable : 413 values
##
##
    -> predict function : yhat.default will be used ( default )
##
    -> predicted values : No value for predict function target column. ( default )
##
    -> model_info
                     : package Model of class: xgb.Booster package unrecognized , ver. Unknown ,
    \rightarrow predicted values : numerical, min = -0.4886776 , mean = 13.90567 , max = 1090.009
##
    -> residual function : difference between y and yhat ( default )
##
                       : numerical, min = -6.749003, mean = 0.0008390863, max = 5.510997
##
   -> residuals
    A new explainer has been created!
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme
train_data[1, ]
      X Y month day FFMC
                          DMC
                                 DC ISI temp RH wind rain area
## 415 5 4
           8 7 93.6 235.1 723.1 10.1 24.1 50 4
bd_xgb_1 <-
 predict_parts(xgb_explainer,
               new_observation = as.matrix(train_data[1, -13]),
               type = "break_down")
shap_xgb_1 <-
 predict_parts(xgb_explainer,
               new_observation = as.matrix(train_data[1, -13]),
               type = "shap")
plot(bd_xgb_1)
```




plot(shap_xgb_1)




İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 463 1 4 9 7 91 276.3 825.1 7.1 14.5 76 7.6 0 3.71
```




plot(shap_xgb_2)




Üçüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme $train_{a}$ train_data[3,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 179 2 5 9 3 90.1 82.9 735.7 6.2 18.3 45 2.2 0 4.88
```



plot(shap_xgb_3)




Dördüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[4,]


```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 195 2 2 8 2 94.8 108.3 647.1 17 24.6 22 4.5 0 10.01
```



plot(shap_xgb_4)




Değişken önem sıralamasını hesaplama ve grafikleme
xgb_var_imp <- DALEX::variable_importance(xgb_explainer)
plot(xgb_var_imp)</pre>




lightgbm

```
# LightGBM veri setlerini tanımlama
train_x <- data.matrix(train_data[,-13])</pre>
train_y <- data.matrix(train_data[, 13])</pre>
test_x <- data.matrix(test_data[,-13])</pre>
test_y <- data.matrix(test_data[, 13])</pre>
lgb_train <- lgb.Dataset(train_x, label = train_y)</pre>
lgb_test <-</pre>
  lgb.Dataset.create.valid(lgb_train, test_x, label = test_y)
# LightGBM modelini early stopping ile eğitme
lgb_model <- lgb.train(</pre>
  params = list('verbose' = -1),
  # Çalışma sırasında çıktıyı gizler
  data = lgb_train,
  nrounds = 100,
  # Maksimum iterasyon sayısı
  valids = list(test = lgb_test) # Doğrulama (validation) seti
\# LightGBM modelini açıklama nesnesiyle açıklama
lgb_explainer <-</pre>
```

```
DALEX::explain(lgb_model, data = as.matrix(train_data[, -13]),
                y = train_data$area)
## Preparation of a new explainer is initiated
     -> model label : R6 ( default )
     -> data
                         : 413 rows 12 cols
##
##
     -> target variable : 413 values
    -> predict function : yhat.default will be used ( default )
##
##
     -> predicted values : No value for predict function target column. ( default )
     -> model info
                        : package Model of class: lgb.Booster package unrecognized , ver. Unknown ,
##
    -> predicted values : numerical, min = 12.5915 , mean = 13.90651 , max = 22.42649
##
    -> residual function : difference between y and yhat ( default )
##
                        : numerical, min = -22.42649, mean = -3.257473e-08, max = 1068.414
##
    -> residuals
##
     A new explainer has been created!
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme
train_data[1, ]
      X Y month day FFMC
                           DMC
                                  DC ISI temp RH wind rain area
## 415 5 4
              8 7 93.6 235.1 723.1 10.1 24.1 50
bd_lgb_1 <-
 predict_parts(lgb_explainer,
               new_observation = as.matrix(train_data[1, -13]),
               type = "break_down")
shap_lgb_1 <-
  predict_parts(lgb_explainer,
               new_observation = as.matrix(train_data[1, -13]),
               type = "shap")
plot(bd_lgb_1)
```



plot(shap_lgb_1)




İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 463 1 4 9 7 91 276.3 825.1 7.1 14.5 76 7.6 0 3.71
```




plot(shap_lgb_2)




Üçüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme $train_{a}$ train_data[3,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 179 2 5 9 3 90.1 82.9 735.7 6.2 18.3 45 2.2 0 4.88
```




plot(shap_lgb_3)




$D\ddot{o}rd\ddot{u}nc\ddot{u}$ $g\ddot{o}zlem$ için Break Down (bd) ve SHAP $de\breve{g}erleri$ hesaplama ve grafikleme $train_data[4,]$


```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 195 2 2 8 2 94.8 108.3 647.1 17 24.6 22 4.5 0 10.01
```



plot(shap_lgb_4)



Değişken önem sıralamasını hesaplama ve grafikleme
lgb_var_imp <- DALEX::variable_importance(lgb_explainer)
plot(lgb_var_imp)</pre>



gbm

```
# GBM modelini oluşturma
gbm_model <-
 gbm(area ~ .,
     data = train_data,
     n.trees = 100,
     distribution = "gaussian")
# GBM modeli ile tahmin yapma
gbm_predictions <- predict(gbm_model, test_data[, -13])</pre>
# GBM modelinin ortalama karesel hatasını hesaplama
gbm_mse <- mean((test_data$area - gbm_predictions) ^ 2)</pre>
\# GBM modelini açıklama nesnesiyle açıklama
gbm_explainer <-</pre>
 DALEX::explain(gbm_model, data = train_data[,-13], y = train_data$area)
## Preparation of a new explainer is initiated
##
    -> model label : gbm ( default )
##
    -> data
                          : 413 rows 12 cols
   -> target variable
                        : 413 values
##
```


```
## -> predict function : yhat.gbm will be used ( default )
## -> predicted values : No value for predict function target column. ( default )
## -> model_info : package gbm , ver. 2.1.8.1 , task regression ( default )
## -> predicted values : numerical, min = -6.030842 , mean = 13.12233 , max = 91.90969
## -> residual function : difference between y and yhat ( default )
## -> residuals : numerical, min = -59.41337 , mean = 0.7841794 , max = 998.9303
## A new explainer has been created!
```

```
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[1,]
```

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 415 5 4 8 7 93.6 235.1 723.1 10.1 24.1 50 4 0 0
```




plot(shap_gb_1)




İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 463\ 1\ 4 9 7 91 276.3 825.1 7.1 14.5 76 7.6 0 3.71
```




plot(shap_gb_2)




Üçüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[3,]

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 179 2 5 9 3 90.1 82.9 735.7 6.2 18.3 45 2.2 0 4.88
```




plot(shap_gb_3)




Dördüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[4,]


```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 195 2 2 8 2 94.8 108.3 647.1 17 24.6 22 4.5 0 10.01
```



plot(shap_gb_4)



GBM modelinin değişken önem sıralamasını hesaplama ve grafikleme
gbm_var_imp <- DALEX::variable_importance(gbm_explainer)
plot(gbm_var_imp)



ionosphere

\$ V6 <dbl> 0.02306, -0.36156, 0.00485, 1.00000, 0.06531, -0.11949, -0.20800, ~ ## \$ V7 <dbl> 0.83398, -0.10868, 1.00000, 0.71216, 0.92106, -0.00763, 0.92806, 1~ ## \$ V8 <dbl> -0.37708, -0.93597, -0.12062, -1.00000, -0.23255, -0.11824, -0.283~

```
## $ V9 <dbl> 1.00000, 1.00000, 0.88965, 0.00000, 0.77152, 0.14706, 0.85996, 0.0~
## $ V10 <dbl> 0.03760, -0.04549, 0.01198, 0.00000, -0.16399, 0.06637, -0.27342, ~
## $ V11 <dbl> 0.85243, 0.50874, 0.73082, 0.00000, 0.52798, 0.03786, 0.79766, -1.~
## $ V12 <dbl> -0.17755, -0.67743, 0.05346, 0.00000, -0.20275, -0.06302, -0.47929~
## $ V13 <dbl> 0.59755, 0.34432, 0.85443, 0.00000, 0.56409, 0.00000, 0.78225, 0.0~
## $ V14 <dbl> -0.44945, -0.69707, 0.00827, 0.00000, -0.00712, 0.00000, -0.50764,~
## $ V15 <dbl> 0.60536, -0.51685, 0.54591, -1.00000, 0.34395, -0.04572, 0.74628, ~
## $ V16 <dbl> -0.38223, -0.97515, 0.00299, 0.14516, -0.27457, -0.15540, -0.61436~
## $ V17 <dbl> 0.84356, 0.05499, 0.83775, 0.54094, 0.52940, -0.00343, 0.57945, 1.~
## $ V18 <dbl> -0.38542, -0.62237, -0.13644, -0.39330, -0.21780, -0.10196, -0.680~
## $ V19 <dbl> 0.58212, 0.33109, 0.75535, -1.00000, 0.45107, -0.11575, 0.37852, -~
## $ V20 <dbl> -0.32192, -1.00000, -0.08540, -0.54467, -0.17813, -0.05414, -0.736~
## $ V21 <dbl> 0.56971, -0.13151, 0.70887, -0.69975, 0.05982, 0.01838, 0.36324, 0~
## $ V22 <dbl> -0.29674, -0.45300, -0.27502, 1.00000, -0.35575, 0.03669, -0.76562~
## $ V23 <dbl> 0.36946, -0.18056, 0.43385, 0.00000, 0.02309, 0.01519, 0.31898, 0.~
## $ V24 <dbl> -0.47357, -0.35734, -0.12062, 0.00000, -0.52879, 0.00888, -0.79753~
## $ V25 <dbl> 0.56811, -0.20332, 0.57528, 1.00000, 0.03286, 0.03513, 0.22792, 1.~
## $ V26 <dbl> -0.51171, -0.26569, -0.40220, 0.90695, -0.65158, -0.01535, -0.8163~
## $ V27 <dbl> 0.41078, -0.20468, 0.58984, 0.51613, 0.13290, -0.03240, 0.13659, 1~
## $ V28 <dbl> -0.46168, -0.18401, -0.22145, 1.00000, -0.53206, 0.09223, -0.82510~
## $ V29 <dbl> 0.21266, -0.19040, 0.43100, 1.00000, 0.02431, -0.07859, 0.04606, 0~
## $ V30 <dbl> -0.34090, -0.11593, -0.17365, -0.20099, -0.62197, 0.00732, -0.8239~
## $ V31 <dbl> 0.42267, -0.16626, 0.60436, 0.25682, -0.05707, 0.00000, -0.04262, ~
## $ V32 <dbl> -0.54487, -0.06288, -0.24180, 1.00000, -0.59573, 0.00000, -0.81318~
## $ V33 <dbl> 0.18641, -0.13738, 0.56045, -0.32382, -0.04608, -0.00039, -0.13832~
## $ V34 <dbl> -0.45300, -0.02447, -0.38238, 1.00000, -0.65697, 0.12011, -0.80975~
## $ V35 <dbl> 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 0, ~
```

Veri setinin özet istatistiklerini inceleme summary(ionosphere)

```
V1
                           ٧2
                                        VЗ
                                                          ۷4
##
                                         :-1.0000
##
           :0.0000
                            :0
                                                           :-1.00000
   Min.
                     Min.
                                 Min.
                                                    Min.
    1st Qu.:1.0000
                     1st Qu.:0
                                  1st Qu.: 0.4721
                                                    1st Qu.:-0.06474
   Median :1.0000
                                 Median : 0.8711
                                                    Median: 0.01631
##
                     Median:0
##
   Mean
           :0.8917
                     Mean
                            :0
                                 Mean
                                         : 0.6413
                                                    Mean
                                                           : 0.04437
##
   3rd Qu.:1.0000
                     3rd Qu.:0
                                  3rd Qu.: 1.0000
                                                    3rd Qu.: 0.19418
##
   Max.
           :1.0000
                     Max.
                            :0
                                  Max.
                                         : 1.0000
                                                    Max.
                                                           : 1.00000
          ۷5
                            ۷6
                                                                 8V
##
                                               ۷7
##
           :-1.0000
                             :-1.0000
                                               :-1.0000
                                                                  :-1.00000
   Min.
                      Min.
                                        Min.
                                                           Min.
   1st Qu.: 0.4127
                      1st Qu.:-0.0248
                                         1st Qu.: 0.2113
                                                           1st Qu.:-0.05484
   Median: 0.8092
                      Median : 0.0228
                                         Median: 0.7287
                                                           Median : 0.01471
##
   Mean
         : 0.6011
                      Mean
                            : 0.1159
                                         Mean
                                               : 0.5501
                                                           Mean
                                                                  : 0.11936
                                         3rd Qu.: 0.9692
##
   3rd Qu.: 1.0000
                      3rd Qu.: 0.3347
                                                           3rd Qu.: 0.44567
##
   Max.
          : 1.0000
                      Max.
                            : 1.0000
                                               : 1.0000
                                                                   : 1.00000
          ۷9
                            V10
                                                V11
##
                                                                    V12
          :-1.00000
                              :-1.00000
                                                  :-1.00000
                                                                      :-1.00000
   Min.
                       Min.
                                           Min.
                                                              Min.
   1st Qu.: 0.08711
                       1st Qu.:-0.04807
                                           1st Qu.: 0.02112
                                                              1st Qu.:-0.06527
##
   Median: 0.68421
                       Median: 0.01829
                                           Median: 0.66798
                                                              Median: 0.02825
                                                              Mean : 0.15504
##
   Mean
         : 0.51185
                       Mean : 0.18135
                                           Mean
                                                : 0.47618
   3rd Qu.: 0.95324
                       3rd Qu.: 0.53419
                                           3rd Qu.: 0.95790
                                                              3rd Qu.: 0.48237
##
          : 1.00000
                              : 1.00000
                                                  : 1.00000
                                                                     : 1.00000
##
   Max.
                       Max.
                                           Max.
                                                              Max.
         V13
                           V14
                                               V15
                                                                 V16
##
           :-1.0000
                      Min. :-1.00000
                                          Min.
                                                 :-1.0000
                                                            Min. :-1.00000
   Min.
```

```
1st Qu.: 0.0000
                      1st Qu.:-0.07372
                                         1st Qu.: 0.0000
                                                          1st Qu.:-0.08170
                                        Median : 0.6019
                                                          Median : 0.00000
   Median : 0.6441
                     Median: 0.03027
   Mean : 0.4008
                     Mean : 0.09341
                                         Mean : 0.3442
                                                          Mean : 0.07113
   3rd Qu.: 0.9555
                      3rd Qu.: 0.37486
                                         3rd Qu.: 0.9193
                                                          3rd Qu.: 0.30897
##
   Max.
         : 1.0000
                     Max. : 1.00000
                                         Max.
                                              : 1.0000
                                                          Max.
                                                                : 1.00000
##
        V17
                          V18
                                              V19
                                                                V20
   Min.
          :-1.0000
                     Min.
                             :-1.000000
                                         Min.
                                                 :-1.0000
                                                           Min.
                                                                   :-1.00000
   1st Qu.: 0.0000
                                          1st Qu.: 0.0000
##
                      1st Qu.:-0.225690
                                                           1st Qu.:-0.23467
##
   Median: 0.5909
                     Median: 0.000000
                                         Median : 0.5762
                                                           Median: 0.00000
   Mean : 0.3819
                     Mean :-0.003617
                                          Mean : 0.3594
                                                           Mean :-0.02402
    3rd Qu.: 0.9357
                      3rd Qu.: 0.195285
                                          3rd Qu.: 0.8993
                                                            3rd Qu.: 0.13437
   Max. : 1.0000
                     Max. : 1.000000
                                          Max. : 1.0000
                                                           Max. : 1.00000
##
##
        V21
                          V22
                                              V23
                                                                V24
                      Min. :-1.000000
                                                            Min.
##
   Min.
          :-1.0000
                                          Min.
                                                :-1.0000
                                                                   :-1.00000
    1st Qu.: 0.0000
                      1st Qu.:-0.243870
                                          1st Qu.: 0.0000
                                                            1st Qu.:-0.36689
##
   Median: 0.4991
                     Median : 0.000000
                                          Median : 0.5318
                                                            Median: 0.00000
         : 0.3367
                     Mean : 0.008296
##
   Mean
                                          Mean : 0.3625
                                                           Mean :-0.05741
    3rd Qu.: 0.8949
                      3rd Qu.: 0.188760
                                          3rd Qu.: 0.9112
                                                            3rd Qu.: 0.16463
   Max. : 1.0000
                     Max. : 1.000000
                                         Max. : 1.0000
                                                           Max. : 1.00000
##
##
        V25
                          V26
                                             V27
                                                               V28
##
   Min.
          :-1.0000
                     Min.
                           :-1.00000
                                               :-1.0000
                                                          Min.
                                                                 :-1.00000
                                        Min.
    1st Qu.: 0.0000
                      1st Qu.:-0.33239
                                         1st Qu.: 0.2864
                                                           1st Qu.:-0.44316
   Median : 0.5539
                     Median :-0.01505
                                         Median : 0.7082
                                                          Median :-0.01769
##
   Mean : 0.3961
                                         Mean : 0.5416
##
                     Mean :-0.07119
                                                          Mean :-0.06954
##
    3rd Qu.: 0.9052
                      3rd Qu.: 0.15676
                                         3rd Qu.: 0.9999
                                                           3rd Qu.: 0.15354
   Max. : 1.0000
                     Max. : 1.00000
                                         Max. : 1.0000
                                                          Max. : 1.00000
##
        V29
                          V30
                                             V31
                                                               V32
##
   Min.
          :-1.0000
                     Min.
                           :-1.00000
                                        Min.
                                               :-1.0000
                                                                 :-1.000000
                                                          Min.
   1st Qu.: 0.0000
                                         1st Qu.: 0.0000
                      1st Qu.:-0.23689
                                                           1st Qu.:-0.242595
   Median: 0.4966
                     Median: 0.00000
                                        Median: 0.4428
                                                          Median: 0.000000
##
   Mean : 0.3784
                     Mean :-0.02791
                                         Mean
                                               : 0.3525
                                                          Mean :-0.003794
##
   3rd Qu.: 0.8835
                      3rd Qu.: 0.15407
                                         3rd Qu.: 0.8576
                                                          3rd Qu.: 0.200120
##
   Max. : 1.0000
                      Max. : 1.00000
                                         Max.
                                              : 1.0000
                                                          Max. : 1.000000
        V33
                          V34
                                             V35
##
          :-1.0000
                     Min. :-1.00000
                                               :0.000
   Min.
                                        Min.
   1st Qu.: 0.0000
                     1st Qu.:-0.16535
##
                                         1st Qu.:0.000
   Median: 0.4096
                     Median : 0.00000
                                        Median :1.000
##
         : 0.3494
                     Mean : 0.01448
   Mean
                                        Mean
                                               :0.641
   3rd Qu.: 0.8138
                     3rd Qu.: 0.17166
                                         3rd Qu.:1.000
##
   Max. : 1.0000
                     Max. : 1.00000
                                        Max.
                                               :1.000
# Veri setini eğitim ve test setlerine ayırma
sample <-
  sample.int(
   n = nrow(ionosphere),
    size = floor(.8 * nrow(ionosphere)),
    replace = FALSE
train data <- ionosphere[sample,]
glimpse(train_data, width = 44)
## Rows: 280
## Columns: 35
## $ V1 <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, ~
```

```
## $ V2 <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
## $ V3 <dbl> 1.00000, 0.68729, 0.50000, 0.5~
## $ V4 <dbl> 0.11765, 1.00000, 0.00000, -0.~
## $ V5
        <dbl> 1.00000, 0.91973, 0.38696, 0.9~
## $ V6
        <dbl> 0.23529, -0.76087, 0.10435, 0.~
        <dbl> 1.00000, 0.81773, 0.49130, 0.5~
## $ V7
## $ V8 <dbl> 0.41176, 0.04348, 0.06522, -0.~
## $ V9 <dbl> 1.00000, 0.76087, 0.46957, 0.3~
## $ V10 <dbl> 0.05882, 0.10702, -0.03913, -0~
## $ V11 <dbl> 1.00000, 0.86789, 0.35652, 0.5~
## $ V12 <dbl> 0.23529, 0.73746, -0.12609, -0~
## $ V13 <dbl> 1.00000, 0.70067, 0.45652, 0.6~
## $ V14 <dbl> 0.11765, 0.18227, 0.04783, 0.2~
## $ V15 <dbl> 1.00000, 0.75920, 0.50435, 0.8~
## $ V16 <dbl> 0.47059, 0.13712, 0.02609, -0.~
## $ V17 <dbl> 1.00000, 0.93478, 0.35652, 0.5~
## $ V18 <dbl> -0.05882, -0.25084, 0.19565, 0~
## $ V19 <dbl> 1.00000, 0.70736, 0.42174, 0.5~
## $ V20 <dbl> -0.11765, 0.18729, 0.14783, 0.~
## $ V21 <dbl> 1.00000, 0.64883, 0.42174, 0.5~
## $ V22 <dbl> 0.35294, 0.24582, -0.02609, 0.~
## $ V23 <dbl> 1.00000, 0.60201, 0.32174, 0.8~
## $ V24 <dbl> 0.41176, 0.77425, -0.11304, 0.~
## $ V25 <dbl> 1.00000, 1.00000, 0.47391, 0.4~
## $ V26 <dbl> -0.11765, -0.53846, -0.00870, ~
## $ V27 <dbl> 1.00000, 0.89262, 0.41789, 0.6~
## $ V28 <dbl> 0.20225, 0.22216, 0.06908, -0.~
## $ V29 <dbl> 1.00000, 0.71070, 0.38696, 0.6~
## $ V30 <dbl> 0.05882, 0.53846, 0.03913, -0.~
## $ V31 <dbl> 1.00000, 1.00000, 0.35217, 0.8~
## $ V32 <dbl> 0.35294, -0.06522, 0.14783, -0~
## $ V33 <dbl> 1.00000, 0.56522, 0.44783, 0.7~
## $ V34 <dbl> 0.23529, 0.23913, 0.17391, -0.~
## $ V35 <dbl> 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, ~
test_data <- ionosphere[-sample,]</pre>
glimpse(test_data, width = 44)
## Rows: 71
```

```
## Columns: 35
## $ V1 <int> 1, 1, 1, 0, 0, 0, 1, 0, 1, 1, ~
## $ V2 <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
## $ V3 <dbl> 1.00000, 0.97588, 1.00000, -1.~
## $ V4 <dbl> -0.18829, -0.10602, -0.16316, ~
## $ V5
        <dbl> 0.93035, 0.94601, 1.00000, 0.0~
## $ V6
        <dbl> -0.36156, -0.20800, -0.10169, ~
## $ V7
        <dbl> -0.10868, 0.92806, 0.99999, 0.~
## $ V8 <dbl> -0.93597, -0.28350, -0.15197, ~
## $ V9 <dbl> 1.00000, 0.85996, 1.00000, -1.~
## $ V10 <dbl> -0.04549, -0.27342, -0.19277, ~
## $ V11 <dbl> 0.50874, 0.79766, 0.94055, 1.0~
## $ V12 <dbl> -0.67743, -0.47929, -0.35151, ~
## $ V13 <dbl> 0.34432, 0.78225, 0.95735, 0.0~
## $ V14 <dbl> -0.69707, -0.50764, -0.29785, ~
```

```
## $ V15 <dbl> -0.51685, 0.74628, 0.93719, 0.~
## $ V16 <dbl> -0.97515, -0.61436, -0.34412, ~
## $ V17 <dbl> 0.05499, 0.57945, 0.94486, 1.0~
## $ V18 <dbl> -0.62237, -0.68086, -0.28106, ~
## $ V19 <dbl> 0.33109, 0.37852, 0.90137, -1.~
## $ V20 <dbl> -1.00000, -0.73641, -0.43383, ~
## $ V21 <dbl> -0.13151, 0.36324, 0.86043, 1.~
## $ V22 <dbl> -0.45300, -0.76562, -0.47308, ~
## $ V23 <dbl> -0.18056, 0.31898, 0.82987, 0.~
## $ V24 <dbl> -0.35734, -0.79753, -0.51220, ~
## $ V25 <dbl> -0.20332, 0.22792, 0.84080, -1~
## $ V26 <dbl> -0.26569, -0.81634, -0.47137, ~
## $ V27 <dbl> -0.20468, 0.13659, 0.76224, 1.~
## $ V28 <dbl> -0.18401, -0.82510, -0.58370, ~
## $ V29 <dbl> -0.19040, 0.04606, 0.65723, 1.~
## $ V30 <dbl> -0.11593, -0.82395, -0.68794, ~
## $ V31 <dbl> -0.16626, -0.04262, 0.68714, -~
## $ V32 <dbl> -0.06288, -0.81318, -0.64537, ~
## $ V33 <dbl> -0.13738, -0.13832, 0.64727, 0~
## $ V34 <dbl> -0.02447, -0.80975, -0.67226, ~
## $ V35 <dbl> 0, 1, 1, 0, 0, 0, 0, 0, 1, 0, ~
```

Ionosphere veri kümesi, radyo frekansı yansımasını incelemek ve atmosferdeki iyonosfer tabakasına yönelik radyo dalgalarının yansımasını tahmin etmek amacıyla toplanmıştır. Bu veri kümesi, özellikle sınıflandırma problemleri için tasarlanmıştır. Veri setinde iki sınıf bulunur: "g" (iyi) ve "b" (kötü). Bu sınıflar, iyonosfer tabakasına yansıyan radyo sinyallerinin özelliklerine dayanarak belirlenir.

Veri kümesi, 34 sayısal özellik içerir. Bu özellikler, radyo dalgalarının farklı açılarda yansımasını temsil eder. Bu özelliklerin her biri, bir radyo sinyalinin iyonosfer tabakasına ne kadar etkili bir şekilde yansıdığını veya yansımadığını açıklar. Bu özelliklerin değerleri, ölçülen fiziksel özelliklerin sonuçlarıdır ve veri kümesinin amacı, bu özelliklerin değerlerine dayanarak bir radyo sinyalinin "iyi" veya "kötü" olduğunu sınıflandırmaktır.

Bu veri kümesi, sınıflandırma algoritmalarının eğitilmesi ve test edilmesi için kullanılabilir. Özellikle, yeni radyo sinyallerinin iyonosfer tabakasına yansıma potansiyelini değerlendirmek için kullanılabilecek bir modelin geliştirilmesine yardımcı olabilir. Ayrıca, bu veri kümesi, makine öğrenimi uygulamalarında sınıflandırma, özellik seçimi ve model değerlendirmesi için birçok farklı deneyin yapıldığı bir test sahası olarak da kullanılabilir.

decision trees

```
# Decision Tree (Karar Ağacı) modelini oluşturma
dt_model <- ctree(V35 ~ ., data = train_data)

# Karar Ağacı modelini görselleştirme
plot(dt_model)</pre>
```

```
# Decision Tree modelini açıklama nesnesi ile açıklama
dt_explainer <-
 DALEX::explain(dt_model, data = train_data[, -35], y = train_data$V35)
## Preparation of a new explainer is initiated
##
    -> model label
                         : BinaryTree ( default )
##
    -> data
                            280 rows 34 cols
##
    -> target variable
                            280 values
    -> predict function :
                            yhat.default will be used ( default )
##
##
    -> predicted values
                         : No value for predict function target column. ( default )
##
    -> model_info
                            package Model of class: BinaryTree package unrecognized , ver. Unknown , t
##
    -> predicted values : numerical, min = 0, mean = 0.6392857, max = 0.9157895
##
    -> residual function : difference between y and yhat ( default )
##
    -> residuals
                         : numerical, min = -0.9157895, mean = 2.750035e-17, max = 0.9666667
##
    A new explainer has been created!
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme
train_data[1, ]
##
      V1 V2 V3
                    V4 V5
                               V6 V7
                                          V8 V9
                                                                            V14
                                                    V10 V11
                                                                V12 V13
                                                                      1 0.11765
## 176 1 0 1 0.11765
                       1 0.23529
                                  1 0.41176 1 0.05882
                                                          1 0.23529
```

V22 V23

V34 V35

1 0.35294

1 0.23529

V24 V25

1 -0.11765

1 0.41176

V20 V21

V32 V33

1 - 0.11765

1 0.35294

V16 V17

V28 V29

V15

V27

1 0.47059

1 0.20225

176


176

V18 V19

V30 V31

1 -0.05882

1 0.05882



plot(shap_dt_1)



İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

۷6

##

V3 V4


۷5

```
V12
                V13
                       V14
                             V15
                                    V16
                                           V17
                                                   V18
                                                          V19
## 235 0.73746 0.70067 0.18227 0.7592 0.13712 0.93478 -0.25084 0.70736 0.18729
         V21
                V22
                       V23
                              V24 V25
                                         V26
                                                V27
                                                       V28
                                                             V29
                                                                    V30
## 235 0.64883 0.24582 0.60201 0.77425
                                   1 -0.53846 0.89262 0.22216 0.7107 0.53846
      V31
             V32
                    V33
                           V34 V35
      1 -0.06522 0.56522 0.23913 0
## 235
bd_dt_2 <-
 predict_parts(dt_explainer,
             new_observation = train_data[2, -35], type = "break_down")
shap_dt_2 <-
 predict_parts(dt_explainer,
             new_observation = train_data[2, -35], type = "shap")
plot(bd_dt_2)
```


۷7

٧8

V10



plot(shap_dt_2)



\ddot{U} çüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[3,]

۷7

۷6

##

V1 V2 V3 V4


۷5

```
## 261 1 0 0.5 0 0.38696 0.10435 0.4913 0.06522 0.46957 -0.03913 0.35652
            V12
                    V13
                            V14
                                    V15
                                            V16
                                                    V17
                                                            V18
                                                                    V19
## 261 -0.12609 0.45652 0.04783 0.50435 0.02609 0.35652 0.19565 0.42174 0.14783
           V21
                    V22
                            V23
                                     V24
                                             V25
                                                     V26
                                                             V27
                                                                      V28
## 261 0.42174 -0.02609 0.32174 -0.11304 0.47391 -0.0087 0.41789 0.06908 0.38696
##
                   V31
                           V32
                                   V33
                                           V34 V35
## 261 0.03913 0.35217 0.14783 0.44783 0.17391
bd_dt_3 <-
  predict_parts(dt_explainer,
                new_observation = train_data[3, -35], type = "break_down")
shap_dt_3 <-
  predict_parts(dt_explainer,
                new_observation = train_data[3, -35], type = "shap")
plot(bd_dt_3)
```


87

V10

V11




plot(shap_dt_3)




$D\ddot{o}rd\ddot{u}nc\ddot{u}$ $g\ddot{o}zlem$ $i\dot{c}in$ Break Down (bd) ve SHAP $de\breve{g}erleri$ hesaplama ve grafikleme $train_data[4,]$


```
##
     V1 V2
              VЗ
                     ۷4
                            ۷5
                                  ۷6
                                         ۷7
                                                ٧8
                                                       ۷9
                                                              V10
V11
                V12
                      V13
                                           V16
                                                  V17
                                                         V18
                             V14
                                    V15
## 306 0.50847 -0.13559 0.64407 0.28814 0.83051 -0.35593 0.54237 0.01695 0.55932
##
        V20
              V21
                     V22
                            V23
                                  V24
                                         V25
                                               V26
                                                      V27
                                                              V28
## 306 0.0339 0.59322 0.30508 0.86441 0.05085 0.40678 0.15254 0.67287 -0.00266
               V30
         V29
                      V31
                             V32
                                    V33
                                           V34 V35
## 306 0.66102 -0.0339 0.83051 -0.15254 0.76271 -0.10169 1
```



plot(shap_dt_4)




Decision Tree modelinin değişken önem sıralamasını hesaplama ve grafikleme
dt_var_imp <- DALEX::variable_importance(dt_explainer)
plot(dt_var_imp)



Random Forest

```
# Veri setini matrise dönüstürme
train_x <- data.matrix(train_data[,-35])</pre>
train_y <- data.matrix(train_data[, 35])</pre>
test_x <- data.matrix(test_data[,-35])</pre>
test_y <- data.matrix(test_data[, 35])</pre>
# Random Forest modelini eğitme
rf_model <- randomForest(x = train_x,</pre>
                         y = as.factor(train_y),
                         ntree = 500)
# Random Forest modelini açıklama nesnesi ile açıklama
rf_explainer <-
  DALEX::explain(rf_model, data = train_data[, -35], y = train_data$V35)
## Preparation of a new explainer is initiated
##
     -> model label
                          : randomForest ( default )
##
     -> data
                          : 280 rows 34 cols
##
     -> target variable : 280 values
##
     -> predict function : yhat.randomForest will be used ( default )
     -> predicted values : No value for predict function target column. ( default )
##
```

```
: package randomForest , ver. 4.7.1.1 , task classification ( default )
##
     -> model info
     -> predicted values : numerical, min = 0 , mean = 0.6458143 , max = 1
##
     -> residual function : difference between y and yhat ( default )
##
##
    -> residuals
                          : numerical, min = -0.36, mean = -0.006528571, max = 0.332
     A new explainer has been created!
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme
train_data[1, ]
##
       V1 V2 V3
                    V4 V5
                               V6 V7
                                           V8 V9
                                                     V10 V11
                                                                 V12 V13
                                                                             V14
## 176 1 0 1 0.11765 1 0.23529 1 0.41176 1 0.05882
                                                          1 0.23529
                                                                      1 0.11765
      V15
              V16 V17
                           V18 V19
                                        V20 V21
                                                    V22 V23
                                                                V24 V25
                                 1 -0.11765
                                               1 0.35294
       1 0.47059
                    1 -0.05882
                                                          1 0.41176
## 176
                                                                      1 -0.11765
       V27
              V28 V29
                          V30 V31
                                       V32 V33
                                                   V34 V35
## 176
        1 0.20225
                    1 0.05882
                                1 0.35294
                                            1 0.23529
bd rf 1 <-
 predict_parts(rf_explainer,
               new_observation = train_data[1, -35], type = "break_down")
shap_rf_1 <-
 predict_parts(rf_explainer,
                new_observation = train_data[1, -35], type = "shap")
plot(bd rf 1)
```




plot(shap_rf_1)

V1 V2

##

V3 V4

۷5



İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

۷6

```
V12
                V13
                       V14
                             V15
                                    V16
                                           V17
                                                  V18
                                                         V19
## 235 0.73746 0.70067 0.18227 0.7592 0.13712 0.93478 -0.25084 0.70736 0.18729
                V22
                       V23
                              V24 V25
                                         V26
                                                V27
                                                       V28
## 235 0.64883 0.24582 0.60201 0.77425
                                   1 -0.53846 0.89262 0.22216 0.7107 0.53846
             V32
                    V33
                           V34 V35
       1 -0.06522 0.56522 0.23913
## 235
bd rf 2 <-
 predict_parts(rf_explainer,
             new_observation = train_data[2, -35], type = "break_down")
shap_rf_2 <-
 predict_parts(rf_explainer,
             new_observation = train_data[2, -35], type = "shap")
plot(bd_rf_2)
```


۷7

٧8


۷9

V10

V11



plot(shap_rf_2)



\ddot{U} çüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[3,]

۷7

87

V10

V11


۷6

##


V1 V2 V3 V4

۷5

```
## 261 1 0 0.5 0 0.38696 0.10435 0.4913 0.06522 0.46957 -0.03913 0.35652
            V12
                    V13
                            V14
                                    V15
                                            V16
                                                    V17
                                                             V18
                                                                     V19
## 261 -0.12609 0.45652 0.04783 0.50435 0.02609 0.35652 0.19565 0.42174 0.14783
           V21
                    V22
                            V23
                                     V24
                                             V25
                                                     V26
                                                             V27
                                                                      V28
## 261 0.42174 -0.02609 0.32174 -0.11304 0.47391 -0.0087 0.41789 0.06908 0.38696
##
                   V31
                           V32
                                   V33
                                           V34 V35
## 261 0.03913 0.35217 0.14783 0.44783 0.17391
bd_rf_3 <-
  predict_parts(rf_explainer,
                new_observation = train_data[3, -35], type = "break_down")
shap_rf_3 <-
  predict_parts(rf_explainer,
                new_observation = train_data[3, -35], type = "shap")
plot(bd_rf_3)
```




plot(shap_rf_3)




Dördüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[4,]

```
##
     V1 V2
              VЗ
                     ۷4
                            ۷5
                                   ۷6
                                         ۷7
                                                 ٧8
                                                       ۷9
                                                              V10
V11
                                            V16
                                                  V17
                                                         V18
##
                V12
                       V13
                             V14
                                    V15
## 306 0.50847 -0.13559 0.64407 0.28814 0.83051 -0.35593 0.54237 0.01695 0.55932
##
        V20
              V21
                     V22
                            V23
                                  V24
                                         V25
                                                V26
                                                      V27
                                                              V28
## 306 0.0339 0.59322 0.30508 0.86441 0.05085 0.40678 0.15254 0.67287 -0.00266
               V30
         V29
                      V31
                             V32
                                    V33
                                            V34 V35
## 306 0.66102 -0.0339 0.83051 -0.15254 0.76271 -0.10169 1
```




plot(shap_rf_4)



Random Forest modelinin değişken önem sıralamasını hesaplama ve grafikleme rf_var_imp <- DALEX::variable_importance(rf_explainer) plot(rf_var_imp)

Feature Importance created for the randomForest model randomForest



SVM

```
# SVM modelini oluşturma
svm_model <-
 svm(
   V35 ~ .,
   data = train_data,
   type = 'C-classification',
   scale = FALSE,
   probability = TRUE
# SVM modelini açıklama nesnesi ile açıklama
svm_explainer <-</pre>
 DALEX::explain(svm_model, data = train_data[, -35], y = train_data$V35)
## Preparation of a new explainer is initiated
##
    -> model label : svm ( default )
                         : 280 rows 34 cols
##
    -> data
    -> target variable : 280 values
##
##
    -> predict function : yhat.svm will be used ( default )
##
    -> predicted values : No value for predict function target column. ( default )
                        : package e1071 , ver. 1.7.11 , task classification ( default )
##
    -> model_info
```

```
\rightarrow predicted values : numerical, min = 0.005215066 , mean = 0.3750405 , max = 0.9999992
##
##
     -> residual function : difference between y and yhat ( default )
                         : numerical, min = -0.9999992, mean = 0.2642452, max = 0.9947849
##
     A new explainer has been created!
##
# İlk gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme
train_data[1, ]
       V1 V2 V3
                     V4 V5
                                V6 V7
                                           V8 V9
                                                     V10 V11
                                                                 V12 V13
                                                                             V14
## 176 1 0 1 0.11765 1 0.23529 1 0.41176 1 0.05882
                                                           1 0.23529
                                                                       1 0.11765
      V15
              V16 V17
                            V18 V19
                                         V20 V21
                                                     V22 V23
                                                                 V24 V25
        1 0.47059
                     1 -0.05882
                                  1 -0.11765
                                               1 0.35294
                                                           1 0.41176
                                                                       1 -0.11765
               V28 V29
                           V30 V31
                                       V32 V33
                                                   V34 V35
      V27
## 176
        1 0.20225
                     1 0.05882
                                 1 0.35294
                                             1 0.23529
bd_svm_1 <-
 predict_parts(svm_explainer,
                new_observation = train_data[1, -35], type = "break_down")
shap_svm_1 <-
  predict_parts(svm_explainer,
                new_observation = train_data[1, -35], type = "shap")
plot(bd_svm_1)
```




plot(shap_svm_1)

V1 V2

##

V3 V4

۷5



İkinci gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[2,]

۷6

```
V12
                V13
                       V14
                             V15
                                    V16
                                           V17
                                                  V18
                                                          V19
## 235 0.73746 0.70067 0.18227 0.7592 0.13712 0.93478 -0.25084 0.70736 0.18729
                V22
                       V23
                              V24 V25
                                         V26
                                                V27
                                                       V28
## 235 0.64883 0.24582 0.60201 0.77425
                                   1 -0.53846 0.89262 0.22216 0.7107 0.53846
             V32
                    V33
                           V34 V35
       1 -0.06522 0.56522 0.23913
## 235
bd svm 2 <-
 predict_parts(svm_explainer,
             new_observation = train_data[2, -35], type = "break_down")
shap svm 2 <-
 predict_parts(svm_explainer,
             new_observation = train_data[2, -35], type = "shap")
plot(bd_svm_2)
```

۷7

٧8


۷9

V10

V11



plot(shap_svm_2)



\ddot{U} çüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[3,]

۷7

۷6

##

V1 V2 V3 V4


۷5

```
## 261 1 0 0.5 0 0.38696 0.10435 0.4913 0.06522 0.46957 -0.03913 0.35652
            V12
                    V13
                            V14
                                    V15
                                            V16
                                                    V17
                                                             V18
                                                                     V19
## 261 -0.12609 0.45652 0.04783 0.50435 0.02609 0.35652 0.19565 0.42174 0.14783
           V21
                    V22
                            V23
                                     V24
                                             V25
                                                     V26
                                                             V27
                                                                      V28
## 261 0.42174 -0.02609 0.32174 -0.11304 0.47391 -0.0087 0.41789 0.06908 0.38696
##
                   V31
                           V32
                                   V33
                                           V34 V35
## 261 0.03913 0.35217 0.14783 0.44783 0.17391
bd_svm_3 <-
  predict_parts(svm_explainer,
                new_observation = train_data[3, -35], type = "break_down")
shap_svm_3 <-
  predict_parts(svm_explainer,
                new_observation = train_data[3, -35], type = "shap")
plot(bd_svm_3)
```


87

V10

V11



plot(shap_svm_3)



Dördüncü gözlem için Break Down (bd) ve SHAP değerleri hesaplama ve grafikleme train_data[4,]

۷5

۷6

۷7

٧8

۷9

V10

##

V1 V2


plot(bd_svm_4)

VЗ


۷4

```
V11
                                              V16
##
                 V12
                        V13
                               V14
                                      V15
                                                    V17
                                                           V18
## 306 0.50847 -0.13559 0.64407 0.28814 0.83051 -0.35593 0.54237 0.01695 0.55932
##
               V21
                      V22
                             V23
                                    V24
                                           V25
                                                  V26
                                                         V27
                                                                 V28
## 306 0.0339 0.59322 0.30508 0.86441 0.05085 0.40678 0.15254 0.67287 -0.00266
         V29
                V30
                       V31
                               V32
                                      V33
                                              V34 V35
## 306 0.66102 -0.0339 0.83051 -0.15254 0.76271 -0.10169 1
bd svm 4 <-
 predict_parts(svm_explainer,
             new_observation = train_data[4, -35], type = "break_down")
shap_svm_4 <-
 predict_parts(svm_explainer,
```


new_observation = train_data[4, -35], type = "shap")



plot(shap_svm_4)



SVM modelinin değişken önem sıralamasını hesaplama ve grafikleme svm_var_imp <- DALEX::variable_importance(svm_explainer) plot(svm_var_imp)



Yorumlar

forestfire

XGboost BD & Shap

```
train_data_ff[1,]

## X Y month day FFMC DMC DC ISI temp RH wind rain area
## 415 5 4 8 7 93.6 235.1 723.1 10.1 24.1 50 4 0 0

train_data_ff[2,]

## X Y month day FFMC DMC DC ISI temp RH wind rain area
## 463 1 4 9 7 91 276.3 825.1 7.1 14.5 76 7.6 0 3.71

train_data_ff[3,]

## X Y month day FFMC DMC DC ISI temp RH wind rain area
```


179 2 5 9 3 90.1 82.9 735.7 6.2 18.3 45 2.2

```
train_data_ff[4,]
```

```
## X Y month day FFMC DMC DC ISI temp RH wind rain area ## 195 2 2 8 2 94.8 108.3 647.1 17 24.6 22 4.5 0 10.01
```

plot(bd_xgb_1)


Break Down profile




plot(bd_xgb_2)




plot(bd_xgb_3)




plot(bd_xgb_4)




plot(shap_xgb_1)




plot(shap_xgb_2)



plot(shap_xgb_3)



plot(shap_xgb_4)



Break Down İlk grafikte (1. gözlem), DMC (Duff Moisture Code) ve DC (Drought Code) değerlerinin model tahmini üzerinde büyük pozitif etkisi olduğunu görüyoruz. Bu iki değişken, orman yangını riskini değerlendirirken orman tabanı ve organik katmanın nem durumunu gösterir ve bu modelde yangın alanını tahmin etmede en belirleyici faktörlerden biri olarak ortaya çıkıyor.

İkinci grafikte (2. gözlem), yine DMC ve DC değerlerinin model tahmini üzerinde büyük pozitif etkisi var, ancak bu sefer rüzgar hızının (wind) da önemli bir etkisi olduğunu gözlemliyoruz. Yüksek rüzgar hızı yangının daha büyük alanlara yayılma riskini artırabilir.

Üçüncü grafikte (3. gözlem), DC'nin yine büyük bir pozitif etki yaptığı görülüyor, ancak DMC'nin etkisi bu sefer negatif. Bunun yanı sıra, göreceli nem (RH) ve rüzgar hızı (wind) gibi diğer değişkenlerin de küçük pozitif katkıları var.

Dördüncü grafikte (4. gözlem), model tahmini üzerinde en büyük pozitif etkiyi yine DMC ve DC'nin yaptığı görülüyor. Ancak bu sefer, ISI (Initial Spread Index) ve sıcaklık (temp) gibi diğer değişkenlerin de model tahminine büyük etkileri olduğu gözlemleniyor.

Shap


- 1. Grafik (1. gözlem): Sıcaklık (temp) ve DMC en büyük negatif etkiye sahipken, DC ve ay (month) en büyük pozitif etkiye sahip. ISI ve göreceli nem (RH) gibi diğer özelliklerin de küçük katkıları var.
- 2. Grafik (2. gözlem): Bu grafikte, DMC'nin yüksek pozitif bir etkisi varken, RH (göreceli nem) ciddi bir negatif katkıya sahip. Diğer özelliklerin katkıları karışık; DC ve ay (month) pozitif, ISI ve rüzgar hızı (wind) negatif katkılar sağlıyor.

- 3. Grafik (3. gözlem): DMC ve ISI'nin küçük pozitif katkıları varken, DC ve ay (month) büyük pozitif etkilere sahip. Sıcaklık (temp) ve RH (göreceli nem) negatif katkılar sağlıyor.
- 4. Grafik (4. gözlem): Bu grafikte, DC ve ay (month) büyük pozitif etkiler gösterirken, temp ve ISI büyük negatif etkiler gösteriyor. DMC ve rüzgar hızının (wind) küçük negatif etkileri var.

XGBoost modeli tarafından üretilen SHAP ve Break Down analizleri, orman yangını risk tahminlerinde DMC ve DC'nin özellikle belirleyici olduğunu göstermektedir. Her iki analiz türü de, sıcaklık ve rüzgar hızının tahminleri önemli ölçüde etkilediğini, ancak bu etkilerin gözlem noktalarına göre değişkenlik gösterdiğini ortaya koymaktadır. Göreceli nemin genellikle yangın riskini düşüren bir faktör olarak öne çıktığı, mevsimsellik etkisinin ise ay değişkeninde açıkça görüldüğü anlaşılmaktadır. Bu analizler, modelin hangi özelliklere daha fazla ağırlık verdiğini ve bu özelliklerin yangın büyüklüğü ve yayılımı üzerindeki potansiyel etkilerini derinlemesine anlamak için kritik bilgiler sağlar.

lighgbm BD & Shap


plot(bd_lgb_1)




plot(bd_lgb_2)




plot(bd_lgb_3)




plot(bd_lgb_4)




plot(shap_lgb_1)




plot(shap_lgb_2)



plot(shap_lgb_3)




plot(shap_lgb_4)




gbm BD & Shap


plot(bd_gbm_1)



plot(bd_gbm_2)



plot(bd_gbm_3)




plot(bd_gbm_4)




plot(shap_gb_1)




plot(shap_gb_2)




plot(shap_gb_3)






Variable Importance


plot(xgb_var_imp)



plot(lgb_var_imp)



plot(gbm_var_imp)



XGBoost Modeli:

- 'temp' değişkeni, bu model için açıkça en önemli özellik olarak öne çıkıyor, diğer tüm değişkenlerden çok daha büyük bir öneme sahip.
- 'Y' ve 'FFMC' değişkenleri de önemli özellikler olarak belirginleşiyor, ancak 'temp' değişkeninin yaklaşık yarısı kadar etkiye sahipler.
- 'DMC', 'DC', 'RH', ve diğer değişkenler daha az öneme sahip ancak yine de modelin tahminleri üzerinde bir etkiye sahip oldukları görülüyor.

LGB Modeli:

- Bu modelde de 'temp' değişkeni en önemli özellik olarak belirlenmiş, ancak XGBoost modeline göre daha az belirgin bir farkla.
- 'Y' ve 'RH' özellikleri de bu modelde önemli olarak sıralanmış.
- 'X', 'ISI', 'wind' ve diğer değişkenlerin önemi göreceli olarak düşük.

GBM Modeli:

- 'temp' değişkeni, GBM modelinde de en önemli özellik olarak karşımıza çıkıyor ve açık bir farkla diğerlerinden öne çıkıyor.
- 'DMC', 'RH' ve 'month' de bu model için önemli özellikler.
- 'DC', 'FFMC', 'day' ve diğer değişkenler daha az önemli ancak hala model tahminlerine katkı sağlıyorlar.

Genel Yorum:

- Tüm modellerde 'temp' değişkeni en önemli özellik olarak sıralanmıştır, bu durum bu değişkenin tahminler üzerindeki güçlü ve tutarlı etkisini gösterir.
- Modelden modele değişken öneminde bazı farklılıklar olsa da, bazı değişkenler (örneğin 'temp', 'Y', 'RH') genel olarak önemli özellikler olarak sıralanmaktadır.

ionosphpere

decision tree BD & Shap

```
train_data[1,]
                                                                      V12 V13
##
       V1 V2 V3
                      V4 V5
                                  V6 V7
                                              V8 V9
                                                         V10 V11
                                                                                   V14
   176
                          1 0.23529
                                      1 0.41176
                                                  1 0.05882
                                                               1 0.23529
                                                                            1 0.11765
               1 0.11765
       V15
                V16 V17
                                                         V22 V23
##
                              V18 V19
                                            V20 V21
                                                                      V24 V25
                                                                                    V26
         1 0.47059
                      1 -0.05882
                                    1 -0.11765
                                                  1 0.35294
##
  176
                                                               1 0.41176
                                                                            1 - 0.11765
##
       V27
                V28 V29
                             V30 V31
                                          V32 V33
                                                       V34 V35
         1 0.20225
## 176
                      1 0.05882
                                   1 0.35294
                                                1 0.23529
train_data[2,]
##
       V1 V2
                   V3 V4
                               V5
                                         V6
                                                 V7
                                                          8V
                                                                   V9
                                                                          V10
                                                                                   V11
##
   235
           0 0.68729
                       1 0.91973 -0.76087 0.81773 0.04348 0.76087 0.10702 0.86789
##
           V12
                    V13
                             V14
                                    V15
                                             V16
                                                     V17
                                                               V18
                                                                        V19
                                                                                 V20
##
   235 0.73746 0.70067 0.18227 0.7592 0.13712 0.93478 -0.25084 0.70736 0.18729
                    V22
                             V23
                                                   V26
                                                            V27
                                                                     V28
                                                                            V29
                                                                                     V30
##
           V21
                                     V24 V25
                                            1 -0.53846 0.89262 0.22216 0.7107 0.53846
## 235 0.64883 0.24582 0.60201 0.77425
                          V33
##
       V31
                 V32
                                  V34 V35
## 235
         1 -0.06522 0.56522 0.23913
train_data[3,]
              V3 V4
                          ۷5
                                   ۷6
                                           ۷7
                                                   8V
                                                            ۷9
                                                                     V10
                                                                             V11
##
       V1 V2
##
           0 0.5
                   0 0.38696 0.10435 0.4913 0.06522 0.46957 -0.03913 0.35652
   261
##
             V12
                     V13
                              V14
                                      V15
                                               V16
                                                        V17
                                                                V18
                                                                         V19
                                                                                  V20
   261 -0.12609 0.45652 0.04783 0.50435 0.02609 0.35652 0.19565 0.42174 0.14783
##
##
           V21
                     V22
                              V23
                                       V24
                                                V25
                                                         V26
                                                                  V27
                                                                          V28
## 261 0.42174 -0.02609 0.32174 -0.11304 0.47391 -0.0087 0.41789 0.06908 0.38696
##
           V30
                    V31
                             V32
                                     V33
                                              V34 V35
```


train_data[4,]

261 0.03913 0.35217 0.14783 0.44783 0.17391


```
##
       V1 V2
                   VЗ
                           ۷4
                                    ۷5
                                            ۷6
                                                     ۷7
                                                              ٧8
                                                                       ۷9
                                                                               V10
           0 0.52542 -0.0339 0.94915 0.08475 0.52542 -0.16949 0.30508 -0.01695
##
  306
       1
           V11
                     V12
                             V13
                                      V14
                                              V15
                                                        V16
                                                                V17
                                                                         V18
##
## 306 0.50847 -0.13559 0.64407 0.28814 0.83051 -0.35593 0.54237 0.01695 0.55932
                   V21
                           V22
                                    V23
                                            V24
                                                    V25
                                                             V26
                                                                      V27
##
##
  306 0.0339 0.59322 0.30508 0.86441 0.05085 0.40678 0.15254 0.67287 -0.00266
           V29
                    V30
                            V31
                                      V32
                                              V33
                                                        V34 V35
## 306 0.66102 -0.0339 0.83051 -0.15254 0.76271 -0.10169
```

plot(bd_dt_1)


Break Down profile




plot(bd_dt_2)




plot(bd_dt_3)




plot(bd_dt_4)




plot(shap_dt_1)




plot(shap_dt_2)



plot(shap_dt_3)




plot(shap_dt_4)




random forest BD & Shap


plot(bd_rf_1)




plot(bd_rf_2)




plot(bd_rf_3)




plot(bd_rf_4)




plot(shap_rf_1)




plot(shap_rf_2)



plot(shap_rf_3)




plot(shap_rf_4)



svm BD & Shap


plot(bd_svm_1)




plot(bd_svm_2)




plot(bd_svm_3)




plot(bd_svm_4)




plot(shap_svm_1)




plot(shap_svm_2)



plot(shap_svm_3)




plot(shap_svm_4)




Variable Importance


plot(dt_var_imp)



plot(rf_var_imp)



plot(svm_var_imp)



DT Modeli:

- 'V5', 'V3' ve 'V1' özellikleri, modelin RMSE'sini en çok etkileyen özellikler olarak sıralanmıştır. Bu, bu özelliklerin değiştirilmesi veya karıştırılması durumunda modelin performansının önemli ölçüde kötüleşeceği anlamına gelir.
- Orta seviyede öneme sahip diğer özellikler ('V9', 'V8', 'V7', vb.) de var ve bunlar da modelin performansını etkiler, ancak en üstteki özellikler kadar belirgin değil.
- En alttaki özellikler ('V10', 'V11', 'V12', vb.), modelin RMSE'sini etkileme konusunda en az öneme sahip özelliklerdir.

RandomForest Modeli:

- 'V5', 'V3' ve 'V7' özellikleri, AUC kaybını en çok etkileyen özellikler olarak sıralanmıştır. Bu özellikler, modelin performansı üzerinde önemli bir etkiye sahip olduğunu gösterir.
- Özelliklerin çoğu, modele göre oldukça düşük bir öneme sahip görünüyor, bu da RandomForest modelinin özellik seçiminde daha yaygın bir etki dağılımına sahip olabileceğine işaret ediyor.

SVM Modeli:

- SVM modeli için 'V2', 'V18', ve 'V28' özellikleri en önemli özellikler olarak sıralanmıştır.
- Bu model, diğer iki modelden farklı olarak, özelliklerin çok geniş bir önem spektrumu gösterdiği için özellik seçiminde daha belirgin bir farklılığa sahip.
- Özellik öneminin daha geniş bir dağılımı olduğunu ve pek çok özelliğin modelin AUC performansını etkilediğini görebiliyoruz.

Genel Yorum:

• Üç model arasında, en önemli özelliklerin sıralamasında bazı tutarlılıklar (örneğin, 'V5' ve 'V3' özelliklerinin yüksek önemi) ve bazı farklılıklar (örneğin, RandomForest modelinde 'V7' özelliğinin yüksek önemi ve SVM modelinde 'V18' özelliğinin önemi) bulunmaktadır.